在軟體開發環境方面，Vivado 用於 FPGA bitstream 產生、RTL 模組整合與硬體設計驗證；LiteX 用於建立 RISC-V soft-core SoC，並整合記憶體控制器、UART、Ethernet 等周邊介面；Colab 則用於模型訓練、遷移學習、量化與 C 推論程式碼匯出。



圖 3.1 系統整體架構與 two-stage 人臉辨識流程

本系統以 Arty A7 FPGA 上之 LiteX RISC-V SoC 作為板端部署平台，透過 Stage 1 人臉候選區域偵測與 Stage 2 量化 CNN 身分辨識完成本地端推論流程。

3.2 軟體模型與量化部署

模型開發採用兩階段資料集建置策略。首先以 WebFace 資料集進行預訓練，再以自建目標人像資料集進行遷移學習。自建資料集共包含 10 個類別，每類配置訓練集 80 張、驗證集 10 張與測試集 10 張。訓練過程加入翻轉、旋轉、仿射變換、色彩擾動、灰階轉換與隨機擦除等資料增強方法，以提升模型對不同光線、角度與背景條件的泛化能力。

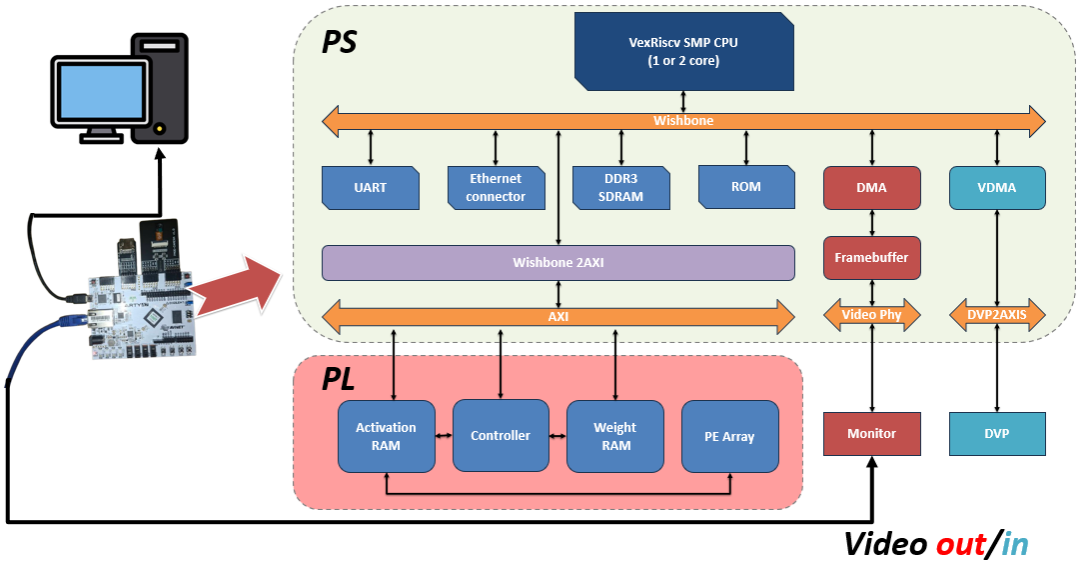


圖 3.2 硬體整體架構。

主機端完成資料集準備、模型訓練、遷移學習與 S8S8 量化後，將量化模型匯出為 C 推論程式與權重檔，並載入 RISC-V SoC 板端進行 Stage 1 偵測與 Stage 2 分類。

本作品採用輕量化 CNN 架構，模型總參數量為 28,691，屬於小型 CNN 模型。訓練時使用 Adam Optimizer、CosineAnnealingLR 學習率調度與 Early Stopping 機制。遷移學習階段則凍結前端卷積層，並替換最後的全連接層，使模型輸出對應至自建資料集之 10 個辨識類別，可降低訓練成本，並保留預訓練模型的能力。

為使模型能部署於無 FPU 之 RISC-V SoC 平台，本作品將 FP32 模型轉換為 S8S8 對稱量化模型，權重與 activation 皆以 signed int8 表示。量化流程包含 BatchNorm Folding、Dynamic Range Calibration、Symmetric Quantization 與 Dual Shift Approximation。BatchNorm Folding 可將 BN 層參數合併至卷積層，減少推論時計算步驟。Dynamic Range Calibration 透過校準資料估計各層 activation 範圍。對稱量化使 zero point 固定為 0，簡化整數運算。Dual Shift Approximation 則將部分 scale 運算近似為位移與加法，以降低板端運算負擔。完成量化後，模型權重與推論流程匯出為 C 程式碼，並於 LiteX RISC-V SoC 上編譯與執行。

整體辨識流程分為 Stage 1 與 Stage 2。Stage 1 以 RGB 影像為輸入，經由 UV chrominance space 膚色偵測、二值化、平滑化、connected components 與幾何條件篩選，找出人臉候選區域。本作品進一步加入 Integral Image 加速平滑化處理，並透過候選區域合併邏輯降低單一人臉被重複偵測的機率。Stage 2 則接收 Stage 1 輸出之人臉 patch 送入量化 CNN 進行身分辨識，最後輸出分類結果、最高分類信心值與各階段執行時間。

3.3 板端量測結果與資源分析

目前系統已完成單核心與雙核心 RISC-V SoC 之板端驗證。量化前後模型準確率維持一致，顯示 S8S8 量化對辨識能力影響有限，不過在進行板端實測則顯示可有效降低整體推論時間。

指標	目前結果	說明
模型參數量	28,691	輕量化 CNN 架構
預訓練模型準確率	81.0345%	WebFace 預訓練結果
遷移學習準確率	77.0833%	自建資料集訓練結果
BatchNorm Folding 後準確率	84.36%	結合動態範圍校準
S8S8 量化後準確率	84.36%	量化後精度下降接近 0%

表 3.2 軟體模型與量化結果